

# III. Databázové a informační systémy (Úvod do databázových systémů, Databázové a informační systémy)


Update: 19. května 2018

## Obsah

|   |  |    |
|---|--|----|
| 1 | Modelování databázových systémů, konceptuální modelování, datová analýza, funkční analýza; nástroje a modely.                | 2  |
| 2 | Relační datový model, SQL; funkční závislosti, dekompozice a normální formy.   | 7  |
| 3 | Transakce, zotavení, log, ACID, operace COMMIT a ROLLBACK; problémy souběhu, řízení souběhu: zamykání, úroveň izolace v SQL. | 15 |
| 4 | Procedurální rozšíření SQL, PL/SQL, T-SQL, trigger, funkce, procedury, kurzory, hromadné operace.                            | 23 |
| 5 | Základní fyzická implementace databázových systémů: tabulky a indexy; plán vykonávání dotazů.                                | 29 |
| 6 | Objektově-relační datový model a XML datový model: principy, dotazovací jazyky.  | 36 |
| 7 | Datová vrstva informačního systému; existující API, rámce a implementace, bezpečnost; objektově-relační mapování.            | 41 |
| 8 | Distribuované SŘBD, fragmentace a replikace.   | 45 |

# 1 Modelování databázových systémů, konceptuální modelování, datová analýza, funkční analýza; nástroje a modely.

## 1.1 Modelování databázových systémů



Databázový systém můžeme modelovat **třemi datovými modely**. Ve fázi analýzy se používá **konceptuální model**, který modeluje realitu na logickou úroveň databáze. Konceptuální model je výsledkem datové analýzy a je **nezávislý na konkrétní implementaci**.

V implementační fázi si pak pomáháme **databázovými modely**, kde modelujeme vazby a vztahy (realitu) na konkrétní tabulky (obecně SŘBD). Databázový model můžeme dále dělit na **relační** a **síťový** model. **Fyzickým uložením dat** na paměťové médium se zabývá **interní model**.

### 1.1.1 Základní pojmy

- **Entita** – objekt reálného světa, konkrétní výskyt instance entitního typu.
- **Entitní typ** – něco jako třída, je popsán jménem a množinou atributů (množina entit se stejnými atributy).
- **Atribut** – vlastnost entity (možné hodnoty jsou označeny jako **doména atributu**).
- **Klíč** – množina atributů, která jednoznačně **určuje entitu**.
- **Vztah/vazba** – definován názvem a vztahem mezi **dvěma entitními** typy.
- **Kardinalita vztahu** – dělení vztahů podle počtu entit vstupujících do vztahu – 1:1, 1:N, M:N.
- **Povinnost v členství** – musí li vztah mezi dvěma entitami existovat, či nemusí.

## 1.2 Datová analýza a konceptuální model

Datová analýza **zkoumá objekty reálného světa, jejich vlastnosti a vztahy**. Zabývá se strukturou obsahové části systému (**strukturou databáze**). Výsledkem datové analýzy je **konceptuální model**. V rámci datové analýzy zpracováváme zadání (specifikaci požadavků na IS):


- podtrhneme **podstatná jména** = identifikujeme **objekty**,
- podtrhneme **slovesa** = identifikujeme **vazby** mezi objekty,
- najdeme **vlastnosti** a **stavy** nalezených objektu = identifikujeme **atributy**.

Z takto získaných informací sestavíme konceptuální model. **Konceptuální model** je jednoduchý **popis entit a jejich vzájemných vztahů**. Jedná se o jakýsi prvotní jednoduchý návrh námi vytvářené databáze. Je kladen důraz na zobrazení všech entit, jejich vztahů a je **nezávislý** na SŘBD. Skládá z:


- **ER Diagram**, lineární zápis **entit**, lineární zápis **vztahů**, **datový slovník**, popis dalších IO (**integritních omezení**).

### 1.2.1 ER (Entity-Relationship) Diagram

Grafické znázornění **konceptuálního modelu** (objektů a vztahů mezi nimi). Může mít několik podob v závislosti na používaném prostředí a detailnosti s jakou jej potřebujeme vypracovat. **Atributy** můžou být v grafu znázorněny **ovály** spojenými s **objekty** (obdélníky), **vazba** 1:N může být znázorněna „hráběmi“ místo N, či celý diagram se může podobat tříd- nímu diagramu s atributy vepsanými do objektu.



**Slabý entitní typ** je označení entity, která **není jednoznačně definována jen svými atributy**, ale i jinou entitou, se kterou je ve vztahu. Tj bez tohoto vztahu by nedávala smysl. Nejčastěji implementováno pomocí složeného primárního klíče ve slabém entitním typu, kde jeden atribut PK je rovněž cizí klíč druhé entity. V příkladu je to položka objednávky, která bez znalosti informací o objednatelce nemá žádnou vypovídací schopnost.



Oracle crow's foot notace pro slabý entitní typ

### 1.2.2 Lineární zápis entit a vztahů

Lineárním zápisem **popisujeme objekty**, jejich vlastnosti a vztahy **z pohledu implementačního**. Lineárním zápisem entit jsou v podstatě definovány **tabulky** a jejich atributy včetně primárních a *cizích klíčů*.

- Příklad lineárního zápisu entity: Pes (IDPes, jmeno, pohlavi, vek, CRasa, IDUtulek).
- Příklad lineárního zápisu vztahů: NABIZI (Útulek, Pes) 1:N.

### 1.2.3 Datový slovník

**Podrobný rozpis jednotlivých atributů.** Tabulka obsahuje typ atributů, velikost, integritní omezení, atd.

**Integritní omezení** obsahují další specifikace atributů, které nejsou dány typem a délkou. Nejčastěji se týkají formátu atributu (podmínka v jakém má být formátu) – např: login se skládá z třech čísel a třech písmen, nebo rodné číslo je složeno z data narození, apod.

**Další integritní omezení** – konceptuální schéma obsahuje také soupis dalších IO, které se týkají entit (tabulek) a vazeb mezi nimi. Může jít například o omezení vícenásobné vazby, vyjádření hierarchie mezi entitama, apod.

| Pes         | Typ     | Délka | Klíč       | NOT NULL | IO                               |
|-------------|---------|-------|------------|----------|----------------------------------|
| IDPes       | int     | 8     | primarni   | ano      | pravidla pro tvar čipového čísla |
| jmeno       | varchar | 50    |            |          |                                  |
| rokNarozeni | int     | 4     |            |          | Validní rok                      |
| CRasa       | int     | 2     | sekundarni |          |                                  |

Tabulka 1: Datový slovník pro tabulku Pes.

## 1.3 Funkční analýza

Zatímco datová analýza se zabývá strukturou obsahové části systému (strukturou databaze), **funkční analýza řeší funkce systému**. Funkční analýza tedy vyhodnocuje manipulaci s daty v systému. Skrze **DFD** (Data Flow Diagramy) **analyzuje toky dat, základní funkce systému a aktéry**, kteří se systémem pracují. Výstupem jsou pak **minispecifikace** – podrobné analýzy elementárních funkcí systému.

Cílem je popsat vytvářený systém jako „černou skříňku“, definovat její **vnější chování** a strukturalizovat **okolí systému**, které se systémem komunikuje. **Popsat všechny funkce, které se budou s daty provádět.**

### Otázky na požadavky

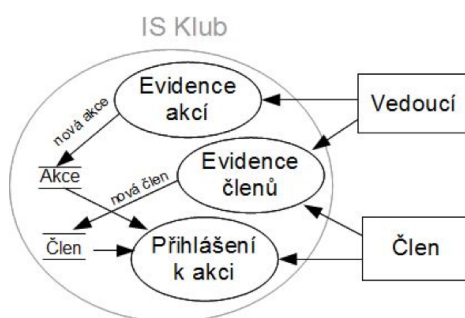
- **PROČ** nový systém.
- **ČEMU** má sloužit.
- **KDO** s ním pracuje - běžně, příležitostně, pravidelně zřídka.
- **VSTUPY** – objekty, atributy
- **VÝSTUPY** – výstupní sestavy, požadované informace
- **FUNKCE** – jaké výpočty, odvozování, výběry, třídění, ...
- **Vazby na OKOLÍ systému** – odkud data a kam.

## Nefunkční požadavky

- Požadavky na **výsledný program**.
- **Vnější požadavky**: ostatní nefunkční implementační požadavky, použití **standardů**, **cenová** omezení, **časové** požadavky.

### 1.3.1 Diagram datových toků (DFD)

DFD je grafický nástroj pro **modelování funkcí a vztahů v systému**. Znázorňuje nejen procesy (funkce) a datové toky, ke kterým v systému dochází, ale definuje také hlavní aktéry a jejich omezení nad systémem. DFD diagram obsahuje tyto prvky: **aktér** (obdélník mimo systém), **proces** (kruh uvnitř systému), **datové toky** (šipky) a **paměť** (viz. obr. Akce a Člen).



DFD diagramy lze zakreslit v různých úrovních. Např. proces Evidence akcí na obrázku lze dále rozkreslit dalším DFD, obsahující procesy vytvoření a editace akce. DFD nejvyšší úrovně se nazývá **kontextový diagram**. Znázorňuje pouze práci aktérů se systémem jako celkem. Systém v kontextovém diagramu vystupuje jako černá skříňka a v diagramu tedy nejsou použity prvky procesu a paměti. **Hlavní znaky DFD:**

- Má několik úrovní podrobnosti.
- Definuje **hranici systému**.
- Definuje **všechny akce**, které mezi systémem a jeho okolím probíhají.

### 1.3.2 Minispecifikace = algoritmy elementárních funkcí

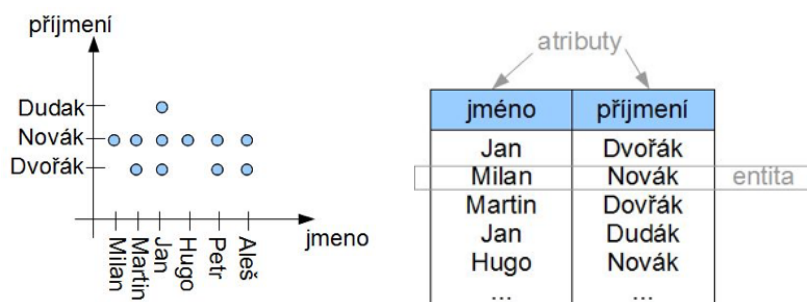
- Popisuje logiku každé z funkcí **poslední úrovně DFD**.
- Každému **elementárnímu (nerozložitelnému) procesu** z poslední úrovně DFD odpovídá **jedna minispecifikace**.
- Popisuje postup, jak jsou **vstupní data transformována na výstupní**.
- Popisuje, co **funkce znamená**, ne jak se to spočítá.
- Používá se **přirozený jazyk** s omezeným množstvím jasně definovaných pojmů, aby byla **srozumitelná** jak pro analytika, tak i uživatele a programátorovi.

```
IF všechny výrobky v objednávce jsou rezervovány,  
THEN pošli objednávku k dalšímu zpracování oddělení prodeje.  
OTHERWISE,  
  FOR EVERY nezarezervovaný výrobek v objednávce DO:  
    Zkus najít volný výrobek a rezervuj ho.  
    IF výrobek není na skladě,  
    THEN informuj správce.
```

## 2 Relační datový model, SQL; funkční závislosti, dekompozice a normální formy.

### 2.1 Relační datový model

Relační datový model představuje **způsob uchování dat v tabulkách**. Relační se mu říká proto, jelikož tabulka je definována přes Relaci.



Obrázek 1: Tabulka s dvěma atributy jako relace (vlevo), relace zobrazena tabulkou (vpravo).

**Relace** je tabulka definována jako **podmnožina kartézského součinu domén**. Relace na obrázku je tedy podmnožina kartézského součinu množin  $\{\text{Dudak, Novák, Dvořák}\} \times \{\text{Milan, Martin, Jan, ..., Aleš}\}$ .

Na rozdíl od matematické relace se ta databázová **mění v čase** (přidáváním a odebíráním prvků relace). Kromě základních **množinových operací** se u databázové relace setkáme s operací **selekce** – výběr řádků a **projekce** – výběr sloupců.

- **Doména** je množina všech hodnot, kterých může daný atribut nabývat (obor hodnot atributu). V praxi je doména dána **integritním omezením** (IO). Doména atributu Příjmení z obrázků je množina  $\{\text{Dudak, Novák, Dvořák}\}$ .
- **Atribut** je vlastnost entity (z pohledu tabulky jde o sloupec).
- **Relační schéma** můžeme chápat jako strukturu tabulky (atributy a domény). Relační schéma  $R$  je výraz tvaru  $R(A, f)$ , kde  $R$  je jméno schématu,  $A = A_1, A_2, \dots, A_n$  je **konečná množina jmen atributů**,  $f$  je zobrazení přiřazující každému jménu atributu  $A_i$  neprázdnou množinu (obor hodnot atributu), kterou nazýváme **doménou atributu**  $D_i$ , tedy  $f(A_i) = D_i$ .

#### Příklad pro tabulku (relaci) Učitel

- **Atributy:** ID, jméno, příjmení, funkce, kancelář.
- **Domény:**
  - $D_1$  – tři písmena z příjmení, tři cifry pořadového čísla,
  - $D_2$  – kalendář jmen,

- D3 – množina příjmení,
- D4 – množina funkcí (asistent, vědec, učitel,...),
- D5 – A101, A102, ... A160.

- **Relační schéma:** Učitel (ID, jméno, příjmení, funkce, kancelář).
- **Relace:** Učitel = {(nov001, lukas , novak , vědec, A135), (kom123, jan, komensky, učitel, A111), ...}

### 2.1.1 Základní úlohy relačního modelu:

1. Návrh „správné“ struktury databáze bez redundancí – funkční závislosti, normální formy.
2. Vyhledávání informací z databáze – (dotazovací) relační jazyky.

### 2.1.2 Vlastnosti relačního datového modelu

Z definice relace vyplývají tyto jejich tabulkové vlastnosti:

- **Homogenita** (stejnorodost) sloupců (prvky domény).
- Každý údaj (hodnota atributu ve sloupci) je **atomickou položkou**.
- Na **pořadí** řádků a sloupců **nezáleží** (jsou to množiny prvků/atributů).
- Každý řádek tabulky je **jednoznačně identifikovatelný** hodnotami jednoho nebo několika atributů (primárního klíče).

### 2.1.3 Vazby relačního modelu

Obecně se vazby v relačním modelu realizují pomocí další relace (tabulky). Jedná se o tzv. **vazební tabulku**. Ta obsahuje ty atributy relací (tabulek, které se vazby účastní), které jednoznačně identifikují jejich entity – primární klíče. Obsahuje-li tabulka atribut, který slouží jako primární klíč v jiné tabulce, pak obsahuje cizí klíč. Vazební tabulka tedy obsahuje cizí klíče. Příklad vazby M:N:

| Učitel |        |           | Učí   |    | Předmět |             |
|--------|--------|-----------|-------|----|---------|-------------|
| idu    | jméno  | příjmení  | idu   | cp | cp      | nazev       |
| dvo01  | Jan    | Dvořák    | dvo01 | 3  | 1       | matematika  |
| kov01  | Marie  | Kovářová  | dvo01 | 1  | 2       | anglický j. |
| kov02  | Martin | Kovadlina | kov01 | 2  | 3       | fyzika      |
| chy01  | Jana   | Chtrá     | chy01 | 1  | 4       | biologie    |
| mal01  | Libuše | Malinová  | mal01 | 5  | 5       | český j.    |



## 2.2 SQL (Structured Query Language)

SQL (Structured Query Language) je **relační jazyk založen na predikátovém kalkulu**. Na rozdíl od jazyků založených na relační algebře, kde se dotaz zadává algoritmem, tyto jazyky se soustředí na to **co se má hledat**, ne jak.

- Standardizovaný **strukturovaný dotazovací jazyk**, který je používán pro práci s daty v **relačních databázích**. (DQL - Data Query Language).
- Navržen IBM jako **dotazovací jazyk** (původní název Sequel).
- Základem je **n-ticový relační kalkul**.
- Standardy podporuje prakticky každá relační databáze, ale obvykle nejsou implementovány vždy **všechny požadavky normy**.
- Obsahuje i příkazy pro **vytvoření** a **modifikace** tabulek, pro **ukládání**, **modifikaci** a **rušení** dat v databázi a řadu dalších příkazů.
- **Příklad:** `CREATE TABLE Drazitel (jmeno CHAR(20), adresa CHAR(30), aukce NUMBER(4), zisk NUMBER(4)); INSERT INTO clovek VALUES( 'nj001', 'Jan', 'Novotný', '777111222');`  
`SELECT telefon FROM clovek WHERE prijmeni = "Novotný";`

### 2.2.1 DML - Data manipulation language

- **Modifikací dat** – INSERT, UPDATE, DELETE = vlož, uprav, smaž.
- **Vyhledávání** v relacích – SELECT, ORDER BY, GROUP BY, JOIN = vyhledej, seřaď, shlukuj, spoj.
- Další, pro podmínky, logické operatory, ... (WHERE, LIKE, BETWEEN, IN, IS NULL, DISTINCT/UNIQUE, JOIN, INNER JOIN, OUTER JOIN, EXISTS, HAVING, COUNT, VIEW, INDEX, ...).

### 2.2.2 DDL - Data definition language

- **Vytváření** a **modifikace** relačního schématu (tabulek, databází) - CREATE, ALTER (MODIFY, ADD), DROP = vytvoř, uprav, smaž.

### 2.2.3 DCL - Data control language

- **Správa práv** - příkazy jako GRANT, REVOKE.

### 2.2.4 TCL - Transaction control language - transakce

- COMMIT - úspěšně provedená transakce, vše se uloží.
- ROLLBACK - zrušení všech změn celé transakce.

- **SAVEPOINT** - uložení bodu, ke kterému lze provést **ROLLBACK**. Tj zruší se jen část transakce a může se pokračovat jinou větví celé transakce dále. Lze tak transakce dělit na menší atomické části.

## 2.3 Relační jazyky

Jazyky pro formulaci požadavků na výběr dat z relační databáze (dotazovací jazyky) se dělí do dvou skupin:

- **Jazyky založené na relační algebře**, kde jsou výběrové požadavky vyjádřeny jako posloupnost speciálních operací prováděných nad daty. Dotaz je tedy **zadán algoritmem**, jak vyhledat požadované informace.
- **Jazyky založené na predikátovém kalkulu**, které požadavky na výběr zadávají jako predikát charakterizující **vybranou relaci**. Je úlohou překladače jazyka nalézt odpovídající algoritmus. Tyto jazyky se dále dělí na
  - **n-ticové** relační kalkuly,
  - **doménové** relační kalkuly.

## 2.4 Relační algebra

Relační algebra je velmi silný **dotazovací jazyk** vysoké úrovně. Nepracuje s jednotlivými entitami relací, ale s **celými relacemi**. Operátory relační algebry se aplikují na relace, výsledkem jsou opět relace. Protože relace jsou množiny, přirozenými prostředky pro manipulaci s relacemi budou množinové operace.

I když relační algebra v této podobě **není vždy implementována v jazycích SŘBD**, je její zvládnutí nutnou podmínkou pro správnost manipulací s relacemi. I složitější dotazy jazyka SQL, který je deskriptivním dotazovacím jazykem, mohou být bez zkušeností s relační algebrou problematické.

### 2.4.1 Základní operace relační algebry

Jsou dány relace **R** a **S**. **Množinové operace:**

- **Sjednocení** relací téhož stupně:  $R \cup S = \{x | x \in R \vee x \in S\}$
- **Průnik** relací:  $R \cap S = \{x | x \in R \wedge x \in S\}$
- **Rozdíl** relací:  $R - S = \{x | x \in R \wedge x \notin S\}$
- **Kartézský součin** relace R stupně m a relace S stupně n:  $R \times S = \{rs | r \in R \wedge s \in S\}$ , kde  $rs = \{r1, ..., rm, s1, ..., sn\}$

**Další relační operace:**

- **Projekce** (výběr atributů) relace R, jedná se o unární operaci  $\Pi_X(R)$ , kde X je množina názvů atributů.

- **Selekce** (výběr řádků) z relace  $R$  podle podmínky  $P$ . Selekcce je unární relační operace  $\sigma_{\varphi(\mathbf{X})}(R)$ , kde  $R$  je relace,  $\varphi(\mathbf{X})$  predikátová formule hovořící o jednotlivých prvcích a jejich příslušnosti do relací.
- **Spojení** relací  $R$  s atributy  $A$  a  $S$  s atributy  $B$  (join). Značí se  $R \bowtie S$ , výsledkem je množina všech kombinací prvků relace  $R$  a  $S$ . Takto definovaný join se nazývá Přírozené spojení (natural join). Existují i další (outer, inner, left, right ...).

Příklad:  $\Pi_{\text{název}} \sigma_{\varphi(\text{pohlaví}=\text{žena})}(\text{Úkol} \bowtie \text{Pracuje} \bowtie \text{Zaměstnanec})$

## 2.5 N-ticový relační kalkul

- Dr. Codd definoval n-ticový relační kalkul pro RDM jazyk matematické logiky - predikátový počet je využit pro výběr informací z relační databáze.
- Název odvozen z oboru hodnot jeho proměnných - **relace je množina prvků = n-tic**.
- Je základem pro jazyk typu SQL.
- Syntaxe je **přizpůsobena** programovacímu jazyku: **matematické vyjádření**  $\{x|F(x)\}$  nahradíme zápisem  $x \text{ WHERE } F(x)$ 
  - Kde  $x$  je proměnná pro hledané n-tice (struktura relace).
  - $F(x)$  je **podmínka**, kterou má  $x$  splňovat (výběr prvků relace).

### 2.5.1 Definice

Výraz n-ticového relačního kalkulu je výraz tvaru  $x \text{ WHERE } F(x)$ , kde  $x$  je jediná volná proměnná ve formuli  $F$ . Základní operace relační algebry se dají vyjádřit pomocí výrazů n-ticového relačního kalkulu, tedy n-ticový relační kalkul je relačně úplný.

|        |                           |   |
|--------|---------------------------|---|
| Platí: | $R \cup S$                | $\Rightarrow x \text{ WHERE } R(x) \text{ OR } S(x)$                            |
|        | $R \cap S$                | $\Rightarrow x \text{ WHERE } R(x) \text{ AND } S(x)$                           |
|        | $R - S$                   | $\Rightarrow x \text{ WHERE } R(x) \text{ AND NOT } S(x)$                       |
|        | $R \times S$              | $\Rightarrow x, y \text{ WHERE } R(x) \text{ AND } S(y)$                        |
|        | $R[a_1, a_2, \dots, a_k]$ | $\Rightarrow x.a_1, x.a_2, \dots, x.a_k \text{ WHERE } R(x)$                    |
|        | $R(P)$                    | $\Rightarrow x \text{ WHERE } R(x) \text{ AND } P$                              |
|        | $R[A*B]S$                 | $\Rightarrow x, y \text{ WHERE } R(x) \text{ AND } S(y) \text{ AND } x.A * y.B$ |

## 2.6 Funkční závislost

Funkční závislost je v databázi **vztah mezi atributy** takový, že máme-li atribut  $Y$  je funkčně závislý na atributu  $X$  píšeme  $X \rightarrow Y$ , pak se **nemůže stát**, aby **dva řádky mající stejnou** hodnotu atributu  $X$  měly **různou hodnotu**  $Y$ . Je-li  $Y, X$  říkáme, že závislost  $X \rightarrow Y$  je **triviální**.

- FZ je definována **mezi dvěma podmnožinami atributů** v rámci jednoho schématu relace. Jde o vztah mezi atributy, nikoliv mezi entitami.
- FZ je definována na **základě všech možných aktuálních relací**, není tedy možné soudit na funkční závislost z vlastností jediné relace. Tak můžeme poznat jen neplatnost funkční závislosti.
- FZ jsou **tvrzení o reálném světě**, o významu atributů nebo **vztahů mezi entitami**, je nutné realitu brát v úvahu při návrhu schématu databáze.

**Příklad:** Atribut '*datum narození*' je funkčně závislý na atributu '*rodné číslo*' (nemůže se stát, že u záznamů se stejnými rodnými čísly bude různé datum narození).

Pomocí funkčních závislostí můžeme **automaticky navrhnout schéma databáze** a předejít problémům jako je **redundance**, **nekonzistence databáze**, zablokování při vkládání záznamů, apod.

## 2.7 Armstrongovy axiomy

K určení **klíče schématu** a logických implikací množiny závislostí potřebujeme **nalézt uzávěr  $F^+$** , nebo určit, zda daná závislost  $X \rightarrow Y$  je prvkem  $F^+$ . K tomu existují pravidla zvaná Armstrongovy axiomy. Jsou **úplná** (dovolují odvodit z dané množiny závislostí  $F$  všechny závislosti patřící do  $F^+$ ) a **bezesporná** (dovolují z  $F$  odvodit pouze závislosti patřící do  $F^+$ ).

- **Reflexivita** – je-li  $Y \subset X \subset A$ , pak  $X \rightarrow Y$
- **Tranzitivita** – pokud je  $X \rightarrow Y$  a  $Y \rightarrow Z$ , pak  $X \rightarrow Z$
- **Pseudotranzitivita** – pokud je  $X \rightarrow Y$  a  $WY \rightarrow Z$ , pak  $XW \rightarrow Z$
- **Sjednocení** – pokud je  $X \rightarrow Y$  a  $X \rightarrow Z$ , pak  $X \rightarrow YZ$
- **Dekompozice** – pokud je  $X \rightarrow YZ$ , pak  $X \rightarrow Y$  a  $X \rightarrow Z$
- **Rozšíření** – pokud je  $X \rightarrow Y$  a  $Z \subset A$ , pak  $XZ \rightarrow YZ$
- **Zúžení** – pokud je  $X \rightarrow Y$  a  $Z \subset Y$ , pak  $X \rightarrow Z$

Závislost, která má na pravé straně pouze jeden atribut, nazýváme **elementární**.

### 2.7.1 Určení klíče pomocí funkčních závislostí

Ze zadání jsme určili atributy  $A = \{\text{učitel, jméno, příjmení, email, předmět, název, kredity, místnost, čas}\}$  a funkční závislosti  $F$ :

- $\text{učitel} \rightarrow \text{jméno, příjmení, email}$
- $\text{předmět} \rightarrow \text{název, kredity}$
- $\text{místnost, čas} \rightarrow \text{učitel, předmět}$

**Rozšíření:**

- učitel, **místnost**, čas → jméno, příjmení, email, **místnost**, čas
- předmět → název, kredity
- místnost, čas → učitel, předmět

#### Dekompozice 1:

- učitel, **místnost**, čas → jméno, příjmení, email, místnost, čas, **učitel**, **předmět**
- předmět → název, kredity

#### Dekompozice 2:

- učitel, místnost, čas → jméno, příjmení, email, místnost, čas, učitel, předmět, **název**, **kredity**

Atributy **učitel**, **místnost**, **čas** je klíč schématu velké relace. V dalším kroku je třeba provést dekompozici a tuto velkou relaci rozbít na menší relace.

## 2.8 Dekompozice

Dekompozice relačního schématu je **rozklad relačního schématu na menší** relač. sch. (rozloží velkou tabulku na menší) aniž by došlo k narušení redundance databáze. Mezi základní vlastnosti dekompozice patří - **zachování informace** a **zachování funkčních závislostí**.

- **Algoritmus dekompozice (metoda shora dolů)** – na počátku máme celé relační schéma se všemi atributy, snažíme se od tohoto schématu odebírat funkční závislosti a tvořit schémata nová. **Exponenciální složitost, BCNF**.
- **Algoritmus syntézy (zdola nahoru)** – vytvoří pro každou funkční závislost novou relaci. Pak tyto malé relace spojuje do větších celků. **Menší složitost, 3NF**.

**Binární dekompozice**, kterou budeme dále řešit je rozklad jednoho relačního schématu na dvě. Obecná dekompozice vznikne postupnou aplikací binárních. Dekompozice relačního schématu  $R(A, f)$  je množina relačních  $RO = \{R_1(A_1, f_2), R_2(A_2, f_2), \dots\}$ , kde  $A = A_1 \cup A_2 \cup A_3 \cup \dots$

## 2.9 Normální formy

Normální formy relací (NF) prozrazují jak dobře je databáze navržena (čím vyšší NF tím lepší).

- **0 NF** – Pokud nesplňuje ani 1 NF, je v 0 NF
- **1 NF** – definuje tabulky, které obsahují **pouze atomické atributy**. Žádné složené atributy - např. v jednom atributu je Jméno i Příjmení.

- **2 NF** – je v 1NF + **každý sekundární atribut je úplně závislý na každém klíči schématu**. Neboli neexistuje závislost sekundárních na podklíči (pokud se klíč skládá z více atributů). Např.: když  $AB \rightarrow CD$ , pak nesmí být  $B \rightarrow C$ . Atribut adresa není závislý na všech klíčích FZ, ale pouze na F.

| <u>firma</u> | adresa | zboží | cena |
|--------------|--------|-------|------|
| F1           | A1     | Z010  | 100  |
| F1           | A1     | Z020  | 50   |
| F2           | A2     | Z020  | 80   |

- **3 NF** – je 2NF + žádný sekundární atribut **není tranzitivně závislý** na žádném klíči schématu. Nesmí existovat závislosti mezi sekundárními atributy (Model auta -> značka auta). Když  $AB \rightarrow CD$ , pak nesmí  $C \rightarrow D$ . **Příklad porušení 3NF** – atribut počet obyvatel je tranzitivně závislý (přes atr. město) na klíči.

| <u>firma</u> | město | obyvatel |
|--------------|-------|----------|
| F1           | M1    | 100 000  |
| F2           | M1    | 100 000  |
| F3           | M2    | 8 000    |

- **BCNF** (Boyce-Coddova normální forma) – 3NF + je-li funkční závislost  $(X \rightarrow Y) \in F+$  a  $Y \notin X$ , pak X obsahuje klíč schématu. **Musí být závislost sekundárních atributů na primárních nikoli naopak**. Když  $AB \rightarrow CD$ , pak nesmí  $C \rightarrow A$ .

Často pokud je splněna 3NF je zároveň splněna i BCNF. Pro nesplnění BCNF je nutné: Aby relace měla více kandidátních klíčů, alespoň 2 z nich musí být složené z více atributů a některé složené klíče musí mít společný atribut.

Příklad relace: PSČ, město, ulice. Toto je validní dle 3NF, ale ne BCNF. Kandidátní klíče jsou tedy PSČ-město a město-ulice. Město je v obou, překrývá se, tudíž není BCNF ale jen 3NF.

### 3 Transakce, zotavení, log, ACID, operace COMMIT a ROLLBACK; problémy souběhu, řízení souběhu: zamykání, úroveň izolace v SQL.

#### 3.1 Transakce

**Logická (nedělitelná, atomická) jednotka práce s databází**, která musí proběhnout buď celá, nebo (v případě že je přerušena) obnovit původní stav databáze a spustit se znovu. Začíná operací **BEGIN TRANSACTION** a končí provedením operací **COMMIT** nebo **ROLLBACK**.

- Obecně zahrnuje posloupnost operací.
- Jejím úkolem je převést **korektní stav databáze** na jiný korektní stav.
- O řízení se stará **manager transakcí** nebo **monitor transakčního zpracování**.
- Operace transakce jsou nejprve zaznamenávány do **logu**.
- Transakce nemohou být vnořovány.
- Všechny SQL příkazy v transakci jsou atomické.
- Nepoužití transakcí může dojít k nekonzistenci databáze.

##### 3.1.1 COMMIT

- Transakce došla úspěšně a změny mohou být **trvale uloženy**, zámky a adresace uvolněny (kromě WITH HOLD).
- Zavádí **potvrzovací bod**.
- Odpovídá úspěšnému ukončení logické jednotky práce a **označuje korektní stav DB**.

##### 3.1.2 ROLLBACK

- Označuje, že databáze může být v **nekorektním stavu** a všechny změny transakce musí být **zrušeny**.

##### 3.1.3 SAVEPOINT

- Rozdělení transakcí na menší části.
- ROLLBACK lze provést pouze částečně, pouze do předem vytvořeného **SAVEPOINTu**, co bylo předem zůstane zachováno. Tím není zrušená celá transakce, ale může klidně pokračovat i nadále dalšími SQL příkazy až do závěrečného **COMMITu**.
- Po ukončení transakce je savepoint zahozen.

### 3.1.4 ACID

Každá transakce by měla splňovat následující vlastnosti:

- **Atomičnost (Atomicity)** – transakce musí být atomická: jsou provedeny všechny operace transakce nebo žádná.
- **Korektnost (Correctness)** – transakce převádí korektní stav databáze do jiného korektního stavu databáze, mezi začátkem a koncem transakce nemusí být databáze v korektním stavu.
- **Izolovanost (Isolation)** – transakce jsou navzájem izolovány: změny provedené jednou transakcí jsou pro ostatní transakce viditelné až po provedení COMMIT.
- **Trvalost (Durability)** – jakmile je transakce potvrzena, změny v databázi se stávají trvalými i po případném pádu systému.

## 3.2 Zotavení

- Nastává po **chybě SŘBD** => Zotavení databáze z nějaké chyby.
- Výsledkem musí být **korektní stav DB**.
- Využívají se **skryté redundantní** informace.
- Jednotkou zotavení je **transakce**.
- Všechny změny jsou zapisovány do logu před zápisem změn do DB => **pravidlo dopředného zápisu do logu**.
- Do logu se zapisuje **sekvenčně**, proto poskytuje **vyšší výkon** než přímý zápis dat.

### 3.2.1 Chyby zotavení

- **Lokální** - pouze v rámci jedné transakce (chyba v dotazu, přetečení hodnoty atributu). Vyskytuje se **10-100x/min** a čas pro zotavení je shodný, jako čas provedení transakce.
- **Globální** - ovlivňují více transakcí najednou:
  - **Systémové (soft crash)** (výpadek proudu, pád systému). Může se vyskytovat i několikrát do roka. Čas potřebný k obnově je několik minut.
  - **Chyby média (hard crash)** - chyba disku (zotavení probíhá ze záložní kopie a z logu jsou obnoveny potvrzené transakce po vytvoření zálohy). Vyskytuje se zřídka a obnova může trvat i hodiny.

### 3.2.2 Průběh zotavení

Základním problémem vzniklým při systémové chybě je ztráta obsahu hlavní paměti, tedy ztráta obsahu vyrovnávací paměti SŘBD. Přesný stav transakce přerušené chybou není znám a transakce musí být **zrušena (UNDO)**. Někdy je transakce úspěšně dokončena,



ovšem změny, nejsou přeneseny z vyrovnávací paměti na disk. V tomto případě musí být transakce po restartu systému přepracována (**REDO**). **Typy zotavení:**

#### **Odloženou aktualizací (deferred update, NO-UNDO/REDO)**

- Neprovádí aktualizace databáze na disk dokud transakce nedosáhne **potvrzovacího bodu**. Všechny změny jsou v paměťovém bufferu.
- Jakmile transakce dosáhne potvrzovacího bodu, tak se **nejprve vše zapíše do REDO logu** a pak do DB (**pravidlo dopředného zápisu do logu**).
- Při selhání transakce není nutné provádět **undo**, změny jsou ztraceny spolu s vyrovnávací pamětí.
- **Redo** se provádí při chybě během zápisu do DB.
- Do logu jsou v případě odložené aktualizace zapsány nové hodnoty (kvůli REDO).
- Minimální I/O operace, používá se pouze pro **krátké a nenáročné transakce** - **hrozí přetečení bufferu**.

#### **Okamžitou aktualizací (immediate update, UNDO/NO-REDO)**

- **Provádí aktualizaci DB** než transakce dosáhne potvrzovacího bodu.
- Operace jsou zapsány do UNDO logu a zároveň je aktualizována DB (pravidlo dopředného zápisu do logu).
- Při chybě je nutné provést **undo**, protože **došlo k aktualizaci DB**.
- Do logu se zapisují **původní hodnoty**, což umožní systému provést UNDO.
- **Velká zátěž disku / nízký výkon**.

#### **Kombinovanou aktualizací (UNDO/REDO)**


- Používaná v praxi. Využívá obou operací v kombinaci s technikou kontrolních bodů.
- Nezapisuje všechny potvrzené operace na disk, místo toho vytváří **kontrolní body**.
  - Zápis operací hromadně po určitém počtu záznamů.
  - Zapisuje se obsah vyrovnávací paměti na disk a záznam o kontrolním bodu do logu.
- Po restartu systému se provádí: **undo** na všechny transakce, které se **nestihly potvrdit** a **redo** na všechny transakce, které **se potvrdily** po vytvoření kontrolního bodu.

### 3.3 Kontrolní body

Kontrolní body jsou vytvářeny např. po určitém počtu záznamů, které byly zapsány do logu a zahrnují:

- zápis obsahu vyrovnávací paměti na disk,
- zápis záznamu o kontrolním bodu do logu.

V případě následující situace musí být:



- Po restartu systému musí být transakce typu  $T_3$  a  $T_5$  zrušeny (undo).
- Transakce typu  $T_2$  a  $T_4$  musí být přepracovány (redo).
- Jelikož změny provedené transakcí  $T_1$  byly provedeny p kontrolním bodem  $t_c$ , tuto transakci při zotavení vůbec neuvažujeme.

**Postup zotavení systému:**

1. Vytvoří se seznamy UNDO a REDO.
2. UNDO se naplní všemi neuloženými transakcemi (vše kromě  $T_1$  na obrázku výše).
3. Procházíme všechny transakce - je v logu COMMIT pro danou transakci -> přesuň transakci do REDO.
4. Všechny transakce z UNDO jsou postupně zrušeny.
5. Všechny transakce z REDO jsou přepracovány a uloženy.
6. Nyní je systém použitelný

### 3.4 Problémy souběhu

- Pro víceuživatelský DB systém (kolik současně). Pro jednouživatelský přístup (SQLite) se toto vůbec neřeší.

- Souběh umožňuje SŘBD zpřístupnit databázi mnoha transakcím ve stejném čase.
- Souběh také přináší mnoho **problémů**, které je nutné řešit i na **aplikační** úrovni.

### 3.4.1 Plán provádění transakce a anomálie

Plán provádění transakce = posloupnost operací transakce, při souběžném provedení - **plán souběžný/paralelní**. Vznikají **3 problémy**:

- **Problém ztráty aktualizace** – jedna transakce **přepíše právě prováděnou hodnotu**. Časová posloupnost: read\_A, read\_B, write\_A, write\_B.

| Transakce A | Čas   | Transakce B |
|-------------|-------|-------------|
| READ $t$    | $t_1$ | -           |
| -           | $t_2$ | READ $t$    |
| WRITE $t$   | $t_3$ | -           |
| -           | $t_4$ | WRITE $t$   |

Obrázek 9.1: Aktualizace transakce A je ztracena v čase  $t_4$ .

- **Problém nepotvrzené závislosti**
  - **Scénář 1 – tr. A pracuje se špatnými daty** - Transakce B zapíše X, transakce A přečte X, transakce B provede ROLLBACK.
  - **Scénář 2 – změna tr. A je ztracena** - Transakce B zapíše X, transakce A zapíše X, transakce B provede ROLLBACK.

| Transakce A | Čas   | Transakce B |
|-------------|-------|-------------|
| -           | $t_1$ | WRITE $t$   |
| READ $t$    | $t_2$ | -           |
| -           | $t_3$ | ROLLBACK    |

Obrázek 9.2: Transakce A se stala v čase  $t_2$  závislou na nepotvrzené změně transakce B.

- **Problém nekonzistentní analýzy** – A provádí součet na účtech, před dokončením B provede přesun z účtu na účet, přičemž 1 už byl započítán a druhý ne. **Špatný součet zůstatků!** A čte committed data (B provede commit, než si A vyžádá další účet), ale i tak to není správné.

| $acc_1 = 30$        | $acc_2 = 20$ | $acc_1 = 50$       |
|---------------------|--------------|--------------------|
| Transakce A         | Čas          | Transakce B        |
| READ $acc_1$        | $t_1$        | -                  |
| $suma = 30$         |              |                    |
| READ $acc_2$        | $t_2$        | -                  |
| $suma = 50$         |              |                    |
| -                   | $t_3$        | READ $acc_3$       |
| -                   | $t_4$        | WRITE $acc_3 = 60$ |
| -                   | $t_5$        | READ $acc_1$       |
| -                   | $t_6$        | WRITE $acc_1 = 20$ |
| -                   | $t_7$        | COMMIT             |
| READ $acc_3$        | $t_8$        | -                  |
| $suma = 110$ ne 100 |              |                    |

Obrázek 9.4: Transakce A provedla nekonzistentní analýzu.

### 3.5 Konflikty čtení/zápis

A a B chtějí číst/zapisovat stejnou entici (záznam). Nastávají 4 možnosti konfliktu:

- **RR (READ-READ)** – negativně se neovlivní, není problém.
- **RW (READ-WRITE)** –  $read_A, write_B = A$  dále počítá s daty  $\rightarrow$  RW zapříčiňuje **problém nekonzistentní analýzy**.  $read_A, write_B, read_A \rightarrow A$  načte odlišené hodnoty = **neopakovatelné čtení (non repeatable read)**
- **WR (WRITE-READ)** –  $write_A, read_B, rollback_A?$   $\rightarrow$  **Problém nepotvrzené závislosti**. Pokud B přečte data  $\rightarrow$  **Špinavé čtení (dirty read)** = čtení non-committed dat.
- **WW (WRITE-WRITE)** –  $write_A, write_B, rollback_A?$   $\rightarrow$  **Ztráta aktualizace** (pro A) a **nepotvrzená závislost** pro B. **Špinavý zápis (dirty write)** - přepisování non-committed dat.

### 3.6 Techniky řízení souběhu

#### 3.6.1 Správa verzí - optimistický přístup

Předpoklad, že se paralelní **transakce ovlivňovat nebudou**. Systém **vytváří** při aktualizaci **kopie dat** a sleduje, která z verzí má být viditelná pro ostatní transakce (podle úrovně izolace).

#### 3.6.2 Zamykání - pesimistický přístup

Předpokládáme, že se paralelní **transakce budou ovlivňovat**. Systém spravuje jednu kopii dat a jednotlivým transakcím přiděluje **zámky**. Používá se nejčastěji.

- Chce-li transakce A provést čtení/zápis nějakého objektu v DB (nejčastěji n-tice), **požádá o zámek** na tento objekt. Žádná jiná paralelní transakce zámek získat nemůže, dokud jej A **neuvolní**.

- **2 typy zámků (existuje jich i více):**
  - **výlučný** zámek (exclusive lock / write lock) **X**.
  - **sdílený** zámek (shared lock / read lock) **S**.
- A má zámek X a B **nedostane žádný zámek** hned. A má zámek S, B **může hned dostat S**, X nikoliv.
- **Matice kompability** - vzájemné vztahy typů zámků, sloupce a řádky: X, S, -; A (okamžitě), N (ne)

|   |   |   |   |
|---|---|---|---|
|   | X | S | - |
| X | N | N | A |
| S | N | A | A |
| - | A | A | A |

- **Operace aktualizace** - mění obsah DB - UPDATE, INSERT i DELETE.
- **Uzamykací protokol** - většinou žádání zámků implicitně → při **získání** n-tice z DB žádán **zámek S**. Při aktualizaci **zámek X**; žádá-li zámek X a má už S, je mu **S změněn na X**; když nemůže být zámek přidělen okamžitě, transakce přechází do stavu **čekání** (wait state).
- Systém musí zajistit aby v tomto stavu nesetřvala navždy - situace "**livelock**" nebo "**starvation**" → řadit požadavky do **fronty** (FIFO). Zámky uvolněny až po operaci COMMIT nebo ROLLBACK.
- **Explicitní uzamykání** - LOCK TABLE <names> IN [ROW SHARE|ROW EXCLUSIVE|SHARE UPDATE|SHARE|SHARE ROW EXCLUSIVE|EXCLUSIVE] MODE [NOWAIT]

### 3.7 Uvážnutí

- **Deadlock** - dvě nebo více transakcí jsou ve stavu **čekání** na uvolnění zámků držených jinou transakcí.
- **Detekce uvážnutí - časové limity** (nastavení max. času pro vykonání transakce), **detekce cyklu v grafu Wait-For** (zaznamenává, které transakce na sebe čekají → u jedné provede ROLLBACK).
- **Prevence uvážnutí pomocí časových razítek** - 2 verze uzamykacího protokolu. Každá transakce na začátku dostane časové razítko (unikátní). Pokud A požaduje zámek na entici, která je zamčená B pak:
  - při **Wait-Die** - pokud je A starší než B, A přejde na čekání; je-li mladší, A je zrušena ROLLBACK a spuštěna znovu.
  - při **Wound-Die** - pokud A je mladší než B, A přejde na čekání; starší → B zrušena ROLLBACK a spuštěna znovu.

- Při opětovném spuštění si transakce nechá své časové razítko. **Nevýhodou** je velký počet operací ROLLBACK. První část jména - situace kdy A je starší než B. **Nemůže nikdy dojít k uváznutí.**

### 3.8 Sériový a serializovatelný plán

- **Ekvivalentní plán** - 2 plány jsou ekvivalentní, pokud dávají shodné výsledky.
- **Sériový plán** - n-tice uspořádaná dle **pořadí vykonávání** jednotlivých transakcí. (transakce jsou provedeny zasebou).
- **Serializovatelný plán** - **plán vykonávání dvou transakcí** je korektní jen tehdy, pokud je serializovatelný → plán ekvivalentní s výsledkem libovolného sériového plánu.

#### 3.8.1 Dvoufázové uzamykání

Transakce které dodržují protokol dvoufázového uzamykání **jsou vždy serializovatelné.**

1. Transakce musí požádat o zámek, než začne pracovat s nějakou enticí.
2. Po uvolnění jakéhokoli zámku nesmí žádat jiný zámek. Všechny držené zámky musí uvolnit.

### 3.9 Úroveň izolace transakce

Serializovatelnost garantuje izolaci transakcí ve smyslu podmínky **ACID**. Je-li plán transakcí serializovatelný, neprojeví se negativní vlivy souběhu. Za izolovanost transakcí se platí **menším výkonem** souběhu → **nižší propustností**. SŘBD umožňuje nastavit úroveň izolace - ta **sníží míru izolace** transakce a **zvýší propustnost**.

Pod pojem špinavé čtení spadá i špinavý zápis. **Výskyt fantomů** nastane v případě:

- Zámek probíhá jen nad existujícími enticemi.
- Pokud provedeme `SELECT .. WHERE xxx BETWEEN 1 AND 10` – dostaneme zámek na všechny entice, které jsou v rozsahu.
- Při vložení nového záznamu s xxx mezi 1 a 10 nebo úpravě jiného kde za xxx bude dosazeno číslo mezi 1 a 10, se při opakovaném čtení objeví fantom. Protože i přes zámek stále dostáváme jiné výsledky, protože dané nové/upravené entice zámek nemají, ale již spadají do podmínky výše.

| Úroveň izolace   | Špinavé čtení | Neopakovatelné čtení | Výskyt fantomů |
|------------------|---------------|----------------------|----------------|
| READ UNCOMMITTED | Ano           | Ano                  | Ano            |
| READ COMMITTED   | Ne            | Ano                  | Ano            |
| REPEATABLE READ  | Ne            | Ne                   | Ano            |
| SERIALIZABLE     | Ne            | Ne                   | Ne             |

## 4 Procedurální rozšíření SQL, PL/SQL, T-SQL, trigger, funkce, procedury, kurzory, hromadné operace.

### 4.1 Procedurální rozšíření SQL

Kromě základních příkazů pro vytváření a modifikaci dat obsahuje SQL trigger, funkce, procedury, kurzory. To umožňuje přenést část aplikační logiky přímo do databáze, čímž se ušetří hodně I/O operací při přenosu dat mezi systémem a DB. Je **závislé na SŘBD** a její různé implementace se mnohdy velice liší:

- **PL/SQL** pro Oracle
- **Transact-SQL** (T-SQL) pro Sybase a MSSQL
- **PL/pgSQL** pro PostgreSQL
- **SQL PL** pro DB2

### 4.2 PL/SQL

- Založeno na jazyku ADA.
- Kód uložen a **prováděn v SŘBD**, může být sdílen více aplikacemi.
- **Nezávislý na aplikační platformě** (pouze na SŘBD).

#### 4.2.1 Proměnné, procedury a funkce

- **Proměnné**
  - Proměnné můžeme rozdělit do několika skupin, dle různých kritérií, nejčastějším dělením je podle **datového typu** na **číselné** (NUMBER), **stringové** (CHAR, VARCHAR2), **datumové** (DATE, TIMESTAMP).
  - Definujeme proměnné `part_no NUMBER(4); in_stock BOOLEAN;`
  - Přiřazení do proměnných je pomocí operátoru `:=`.
- **Anonymní procedury**
  - **Nepojmenované** procedury které **nejde volat**, jsou spuštěny a zahozeny.
  - Mohou být uloženy v souboru nebo spuštěny přímo z konzole.
  - Jsou pomalejší než pojmenované procedury, protože **nemohou být předkompilovány**.
- **Pojmenované procedury**
  - Obsahují **hlavičku se jménem a parametry**. Díky tomu se dají volat z jiných procedur či triggerů nebo spuštěny příkazem **EXECUTE**.
  - Jelikož jsou **kompilovány** jen jednou, jsou rychlejší než anonymní.

- `CREATE [OR REPLACE] PROCEDURE jmeno_procedury [( jmeno_parametru [mod] datovy_typ , ... )] IS|AS definice lokálních proměnných BEGIN tělo procedury END [jmeno_procedury]`

- **Funkce**

- Na rozdíl od procedury **vrací hodnotu**. Kromě standardních funkcí (`TO.CHAR`, `TO.DATE`, `SUBSTR`, apod.) si můžeme definovat **vlastní funkce**.
- Lze následně používat v SQL dotazech jako je `SELECT` apod.
- `CREATE [OR REPLACE] FUNCTION jmeno_funkce [( jmeno_parametru [mod] datovy_typ , ... )] RETURN navratovy_datovy_typ IS |AS definice lokálních proměnných BEGIN tělo procedury END [jmeno_procedury]`

#### 4.2.2 Dynamické a statické PL/SQL

- **Statické PL/SQL** - klasické procedury, které mají vázané proměnné.
- **Dynamické PL/SQL** - kód SQL příkazu je vytvářen dynamicky za běhu - vytvoření textového řetězce a jeho spuštění příkazem `EXECUTE IMMEDIATE`.

#### 4.2.3 Výjimky, podmínky, cykly

- **Výjimky**

- Vznikají ručně i ze systému.
- Zpracování v bloku `EXCEPTION`
- Pro ruční vyvolání je nutné ji deklarovat (`DECLARE vyjimka EXCEPTION;`) a vyhodit (`RAISE vyjimka`)

- **Podmínky**

- `IF podminka1 THEN příkazy [ELSIF podminka2 THEN příkazy ] [ELSE příkazy ] END IF ;`

- **Cykly**

- `do while`-LOOP příkazy cyklu `[EXIT; | EXIT WHEN podminka ;] END LOOP;`
- `while do` - WHILE podminka LOOP příkazy cyklu `END LOOP;`
- `for`-FOR `jmeno_promenne` IN `[REVERSE] value1 .. value2` LOOP příkazy cyklu `END LOOP;`

#### 4.2.4 Kurzory, trigger, hromadné operace

- **Trigger**

- Kód spouštěný v reakci na **událost** (DML, DDL, systémové eventy).



- Lze určit kdy se má spouštět - BEFORE, AFTER, INSTEAD OF.
- Při jaké události se má spustit - INSERT, UPDATE, DELETE - lze specifikovat i více akcí najednou.
- V PL/SQL FOR EACH ROW - Tělo triggeru se bude volat pro každý řádek zvlášť, nikoli najednou.
- Lze používat speciální proměnné obsahující starou a novou hodnotu :OLD, :NEW.
- Pokud se pokusíme v triggeru číst či modifikovat stejnou tabulku dostaneme **mutating table error**.
- CREATE [OR REPLACE ] TRIGGER jmeno\_triggeru BEFORE | AFTER | INSTEAD OF INSERT [OR] | UPDATE [OR] | DELETE [OF jmeno\_sloupce] ON jmeno\_tabulky [REFERENCING OLD AS stara\_hodnota NEW AS nova\_hodnota] [FOR EACH ROW [WHEN (podminka )]] BEGIN příkazy END;.

## • Kurzory

- Kurzor je ukazatel na řádek **víceřádkového výběru**. Je třeba jej v programu deklarovat pokud budeme zpracovávat víceřádkové výběry. Kurzorem mohu pohybovat a tak se dostanu na další řádky výběru. Zdrojem kurzoru je vždy SQL dotaz a jsou dva typy:
  - \* **implicitní** - vytváří se **automaticky** po provedení příkazu INSERT, UPDATE, DELETE.
  - \* **explicitní** - **ručně vytvořený kurzor**. Vytváří se nejčastěji ve spojení s příkazem SELECT.
- **Příkazy pro práci s kurzorem:**
  - \* CURSOR kurzor IS select; - vytvoření kurzoru.
  - \* OPEN kurzor - otevře kurzor, tedy nastaví ho na první řádek.
  - \* FETCH kurzor INTO promena - příkaz pro pohyb kurzoru. Načte aktuální záznam do proměnné a posune se na další záznam.
  - \* CLOSE kurzor - uzavře kurzor.

## • Vázané proměnné

- SŘBD kontroluje **jedinečnost dotazu**, pokud už byl dotaz v minulosti proveden, použije se **dříve použitý plán** dotazu místo nového vytváření plánu.
- Vázané proměnné umožňují **parametrizaci hodnot v dotazu**, odpadá tedy opětovné vytváření plánu pro stejný dotaz s jinou hodnotou.
- Lze používat i v dynamickém PL/SQL (pomocí **USING**).
- Použití i při volání z aplikace (podpora v C# i Java).

## • Hromadné operace

- Snížení režie na zotavení (zápis do logu) a aktualizace DB (datových struktur). Výsledkem je rychlejší vkládání záznamů do DB.
- Lze použít pro statické i dynamické SQL.
- BULK COLLECT
  - \* **Hromadné načtení** (navázání vstupní kolekce s PL/SQL enginem).
  - \* BULK COLLECT INTO collection\_name[, collection\_name]
- FORALL
  - \* Hromadná **operace** (navázání vstupní kolekce před posláním do SQL enginu)
  - \* FORALL index IN lower\_bound..upper\_bound [INSERT, UPDATE nebo DELETE];

- **Balíky**

- Obdoba kníhoven v programovacích jazycích.
- Specifikace balíku a následně tělo.

### 4.3 T-SQL (Transact-SQL)

Transact-SQL (T-SQL) je proprietární rozšíření jazyka SQL od společností **Microsoft** a **Sybase**, které Microsoft používá v produktu **Microsoft SQL Server**, Sybase Software pak v Adaptive Server Enterprise.

#### 4.3.1 Proměnné, procedury a funkce

- **Proměnné**

- **Deklarace** pomocí DECLARE @TMP INT.
- **Inicializace** pomocí SET nebo SELECT.

- **Podmínky**

- IF <boolean condition > <statement> ELSE <statement>
- Více příkazů v jedné větvi musíme obalit do BEGIN/END.

- **Cykly**

- WHILE <Boolean expression> <code block>

- **Transakce**

- **Začátek** - BEGIN TRANSACTION <nazev\_transakce>
- **Konec** - ROLLBACK nebo COMMIT
- **Nastavení úrovně izolace** - SET TRANSACTION ISOLATION LEVEL <level>

- **Výjimky**

- Bloky try/catch (BEGIN TRY/END TRY a BEGIN CATCH/END CATCH).

- **Uložené procedury**

- Uloženy v SŘBD.
- Předkompilovány, tudíž jsou rychlejší.
- `CREATE PROC[EDURE] procedure_name [;number] [ @parameter data_type [VARYING] [= default ] [OUTPUT] ] [ , . . . ] [ WITH RECOMPILE | ENCRYPTION | RECOMPILE, ENCRYPTION ] [FOR REPLICATION] AS sql_statement`

- **Uložené funkce**

- Není možné použít try/catch, DML atd.
- Musí vracet hodnotu.
- `CREATE FUNCTION [ schema_name. ] function_name ( [ @parameter_name [ AS ] [ type_schema_name . ] parameter_data_type [ = default ] [ READONLY ] [ ,...n ] ] ) RETURNS return_data_type [ WITH <function_option > [ ,...n ] ] [ AS ] BEGIN function_body RETURN scalar_expression END [ ; ]`

#### 4.3.2 Kurzory, trigger, dynamické SQL

- **Kurzory**

- `DECLARE cursor_name CURSOR FOR select_statement`
- **Musíme použít** sekvenci příkazů: OPEN, FETCH, CLOSE, DEALLOCATE
- Pro testování prázdného kurzoru používáme @@FETCH\_STATUS

- **Trigger**

- `CREATE TRIGGER [ schema_name . ] trigger_name ON table | view [ WITH <dml_trigger_option > [ ,...n ] ] FOR | AFTER | INSTEAD OF [ INSERT ] [ , ] [ UPDATE ] [ , ] [ DELETE ] [ WITH APPEND ] [ NOT FOR REPLICATION ] AS sql_statement [ ; ] [ ,...n ] | EXTERNAL NAME <method specifier [ ; ] >`

- **Dynamické SQL**

- Podobné PL/SQL, pomocí příkazu `sp_executesql`
- `sp_executesql [@stmt =] stmt [ , [@params =] N'@parameter_name data_type [ ,... n] ' , [@param1 =] 'value1 ' [ ,... n] ]`

#### 4.4 Rozdíly PL/SQL vs T-SQL

- **T-SQL neposkytuje operátory** jako %TYPE a %ROWTYPE pro získání datových typů existujících záznamů.

- **T-SQL nepodporuje** `CREATE OR REPLACE PROCEDURE`, což nás nutí k tomuto zápisu:  
`/*CREATE*/ ALTER PROCEDURE.`
- **T-SQL** podstatně **omezuje konstrukce**, které můžeme využívat ve funkcích.
- V **T-SQL** musím při práci s kurzory používat `OPEN`, `FETCH`, `CLOSE`, `DEALLOCATE`.
- **T-SQL** nás nutí k dvojitému `FETCH` u kurzorů.
- V **T-SQL** musíme definovat u parametrů procedur a funkcí **délku datového typu** (pokud se u datového typu udává).
- V **T-SQL** musíme více příkazů v jedné větvi obalit do `BEGIN/END`.

## 5 Základní fyzická implementace databázových systémů: tabulky a indexy; plán vykonávání dotazů.

### 5.1 Fyzická implementace

Fyzická implementace definuje **datové struktury** pro základní logické objekty:

- **tabulky**,
- **indexy**,
- **materializované pohledy** (materialized views),
- **rozdělení dat** (data partitioning) – data s dlouhou historií. Fyzické rozdělení datových struktur a souboru na více částí.

Fyzická implementace tedy **řeší uložení dat na nejnižší úrovni databáze**. Na úrovni databáze můžeme ovlivnit výběr efektivnějšího plánu vykonávání dotazu případně **dobu vykonávání operací**.

- **ROWID** – jedinečné číslo **označující záznam tabulky**.
- Větší část teorie fyzického návrhu DB je platná pro libovolné SŘBD, dále se musíme řídit **doporučením výrobce**.
- Každé SŘBD obsahuje specifickou reprezentaci tabulek a indexů:
  - **CREATE TABLE** - vytvoření tabulky typu **halda** (Oracle), **shlukování záznamů** (SQL Server 2012).
  - **CREATE INDEX** - vytvoření **B+-stromu**, kde každá položka odkazuje na ROWID záznamu v tabulce.

### 5.2 Datové struktury

Datové struktury **se skládají** buďto ze **stránek**, nebo z **uzlů** v případě stromové struktury. Jejich realizace přímo ovlivňuje efektivitu **operací** vyhledávání, vkládání, editace a mazání. Konkrétní realizace je závislá na použitém typu tabulky (halda, halda+index, shlukování záznamů).

Základní datové struktury:

- **Blok** (alokační jednotka) – je nejmenší jednotka, se kterou SŘBD manipuluje při zápisu a čtení dat z disku (obvykle 4KB nebo 8KB).
- **Stránka** – nejmenší jednotka s kterou pracuje správce paměti.  $\text{Stranka.velikost} = X * \text{Blok.velikost}$  (je-li velikost bloku = 4KB je odpovídá velikost stránky násobkům 4KB).
- **Datový soubor** – fyzický prostor na disku s daty.

## 5.3 Typy tabulek

### 5.3.1 Heap Table

- Implicitní pro CREATE TABLE téměř všude, pokud tabulka nemá žádné indexy (ani PK). Záznamy nejsou nijak uspořádány.
- **Stránkové perzistentní pole** s velikostí **bloku** nejčastěji **8kB**.
- Záznamy pouze **označovány jako smazané**, pro fyzické smazání slouží speciální operace **shrinking**.
- Obsahuje všechny záznamy a jejich atributy pokupě.
- Při vkládání záznam uložen na **první volnou pozici v tabulce** nebo na **konec pole**.
- Složitost operací: neefektivní vyhledávání  $O(n)$ , velmi **efektivní vkládání**  $O(1)$  i **využití místa**.

### 5.3.2 Shlukování záznamů (Data Clustering)

- Implicitní pro MS-SQL při CREATE TABLE
- Záznamy v **datovém souboru jsou seřazeny podle zvoleného klíče**, pro implementaci nejčastěji využita nějaká **varianta B-stromu**.
- Listové uzly stromu (bloky) obsahují **kromě klíče i další atributy** tabulky.
- V pokročilejších DBMS lze zvolit, které atributy leží přímo v B+ stromu a které leží na haldě. Lze tak kombinovat shlukování s heap table. Pro získání dat uložených přímo v listu není přístup na haldu poté nutný
- Používá se všude, kde potřebujeme **získat i hodnoty ostatních atributů** (kromě klíče - např. SELECT neklíčových atributů) - vyšší výkon
- **Zhoršený výkon** INSERT (data se musí zatřizovat).
- **Oracle:** Index Organized Table (IOT), **SQL Server:** Clustered Index.

**Eliminace náhodných přístupů přes ROWID** Tabulka se shlukováním záznamů může ušetřit náhodný přístup oproti heap table a indexu. Po vyhledání ve stromě není nutné další náhodný přístup na haldu, protože vše potřebné je v listu. Kvůli více datům v listech může ale být celková výška stromu ve shlukované tabulce mnohem větší. To způsobí více náhodných přístupů při průchodu stromem než v případě heap table a indexu. Co je lepší nelze určit předem ale pouze testem na reálných nebo pseudoreálných datech.

### 5.3.3 Hašovaná tabulka (Hash Table)

- Záznamy se stejnou hashovanou hodnotou jsou uloženy ve stejném nebo velmi blízkém bloku.
- Trochu **plýtvá místem**.

- Musíme znát předem velikost záznamů (alespoň přibližně).

### 5.3.4 Materializované pohled (Materialized views)

- Uložené **výsledky dotazů**, které bývají často v DB vyhodnocovány.
- Jde spíše o **fragment** z **tabulky** či několika tabulek.

## 5.4 Indexy

Indexové soubory slouží k možnosti **rychlého vyhledávání a seřazení tabulky** podle různých atributů. Tabulka je jinak seřazena úplně náhodně (heap table), nebo podle primárního klíče (data-clustering). Index je tedy vázaný ke konkrétní tabulce a konkrétnímu atributu. Index umožňuje **rychlé vyhledávání** dle klíče, **ROWID pak odkazuje na kompletní záznam v heap tabulce**. `CREATE [BITMAP] INDEX login ON Student;` Protože ale následný počet náhodných přístupů pomocí ROWID může být mnoho, někdy DB raději provede sekvenční prohledání celé tabulky. Rozhoduje se individuálně na základě statistik o attributech a jejich velikostech.

- **Primární index (PRIMARY)** – automatický index, který se váže k primárnímu klíči, zajišťuje jedinečnost údajů.
- **Unikátní index (UNIQUE)** – stejně jako primární index zajišťuje jedinečnost údajů v atributu, ale neváže se k primárnímu klíči.
- **Vedlejší index (INDEX)** – klasické index popsány níže.
- **Fulltextový index** – používá se pro optimalizaci fulltextového vyhledávání v daném sloupci.
- **Složený index** – Může být kterýkoli výše. Obsahuje více atributů v jednom klíči. Pokud je dotaz jen na druhý či další atribut v indexu, nelze index použít.


### 5.4.1 Nevýhody indexů

- Při velkém množství různých indexů mohou soubory s index zabírat mnohem více než samotná tabulka
- Pro získání dalších dat je nutné hodně náhodných přístupů přes ROWID
- Každý záznam v indexu musí být shodné délku. Tj například stringy nejsou vhodné pro index, protože každý záznam v indexu bude tak dlouhý, jaký je nejdelší možný string daného atributu. Pokud je string kratší, je záznam v indexu vyplněn 0.

### 5.4.2 Bitmapový index

Odpovídá na **všechny možné hodnoty daného atributu**. Jde o tabulku jedniček a nul, kde řádky reprezentují záznamy v indexované tabulce a sloupce hodnoty indexovaného

atributu. Jednička pak znamená true, že záznam má hodnotu danou sloupcem. **Vyplatí se**, pokud se používají logické operátory (AND, OR, XOR) nad několika bitmapovými indexy atributů.



### 5.4.3 Shlukovaný index (Cluster Index)

Pokud se pro dvě tabulky často používá operace spojení (JOIN) pro jeden atribut. V tomto případě diskový blok obsahuje záznam z řídicí tabulky a zároveň i závislé záznamy. (v normálním případě obsahuje diskový blok pouze záznamy jedné tabulky).

### 5.4.4 Kandidáti na index

- Primární klíče a cizí klíče.
- Pokud je index používán pro nalezení malého počtu záznamů.
- Pokud index pokryje jeden nebo více častých dotazů.
- Atributy často se vyskytující v konstrukci WHERE.

## 5.5 Vykonávání dotazu

**Ovlivnění času vykonávání dotazu** - parametrizované dotazy, hromadné operace, nastavení transakcí. Na úrovni DB můžeme ovlivnit výběr efektivnějšího plánu vykonávání dotazu, případně dobu vykonávání operací -> **fyzický návrh DB**. Identifikujeme **4 fáze vykonávání dotazu**:

#### 1. Parsování dotazu

- Převod původního dotazu do zvolené **interní formy**.
- **Eliminujeme syntaxi jazyka dotazu** (např. SQL).
- Zpracování pohledů, které probíhá v této fázi, znamená, že **nahradíme pohled jeho definicí** (materializované pohledy – fragmenty/výsledky dotazů).



- Interní forma je nejčastěji **nějaký druh dotazovacího stromu** (angl. query tree).

## 2. Výběr logického plánu

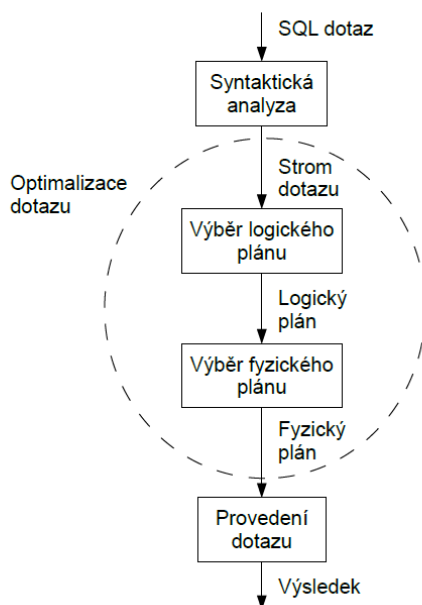
- při převodu do formy relační algebry dochází také k **odstranění** různých povrchních **rozdílů** a především nalezení **efektivnějšího tvaru** než nabízel původní dotaz.
- **Optimalizátor** – transformační pravidla (převádí výraz na ekvivalentní). Fáze transformace/přepsání dotazu (query rewrite). Dotaz tedy není ve skutečnosti vykonán přesně tak, jak byl zadán!

## 3. Výběr fyzického plánu

- V této fázi se optimalizátor rozhoduje jak bude transformovaný dotaz vykonán.
- Jsou vybírány konkrétní algoritmy a pořadí jejich vykonávání.
- Při výběru se již uvažuje: **existenci indexů**, **distribuci hodnot**, **shlukování uložených dat**.
- Každé operaci je přiřazena výsledná **cena** = **IO cost** + **CPU cost**, která bude potřebná k celkovému vykonání.

## 4. Výběr nejlevnějšího plánu a jeho vykonání

- Z množiny dotazovacích plánů pak **optimalizátor** vybírá ten **nejlepší**, tedy **nejlevnější** plán.
- Následně je vykonán a hodnoty vráceny.



## 5.6 Optimalizátor a ladění dotazů

- **Optimalizátor** pro nalezení nejlepšího plánu využívá systémový katalog, který obsahuje statistiky o uložených datech. Systémový katalog je aktualizován v době nejmenší zátěže serveru, nikoli po každé CRUD operaci. Orientační obsah katalogu:
  - **Tabulka** - kardinalita (mohutnost, počet záznamů), počet diskových stránek
  - **Sloupec** - počet stejných hodnot ve sloupci, minimální a maximální hodnoty, null hodnoty,  $X$  nejfrekventovanějších hodnot
  - **Index** - Počet listových stránek, výška stromu
- **Plán** lze v SŘBD většinou **zobrazit** - operace jako průchod tabulkou, přístup k indexu, třídění spojení atd. To lze využít pro **odladění dotazu** - např. uvidíme, že musíme použít index na neindexovaný atribut.
- Dvěma či více **různými dotazy** je možno obdržet **stejná data**.
- **Rychlost** různých dotazů ovšem **nemusí být stejná** i přesto, že vracejí stejná data.
- Snažíme dosáhnout **maximálního výkonu** se **stávajícími prostředky**.
- Snažíme se vytvořit dotaz, který **bude načítat z úložiště pouze to, co potřebuje**.

### 5.6.1 Přístupy k ladění

- **Proaktivní** – Analyzujeme fyzický návrh a provádíme změny k lepšímu fungování.
- **Reaktivní** – Reagujeme na problém.

### 5.6.2 Ladění výkonu SŘBD

- **HW** – RAID, RAM, CPU (Poslení možnost, je to drahé, efektivnější je **vyladit fyzický návrh**).
- **Parametry SŘBD** – Velikosti **cache**, maximum zámků, atd. Nutné optimalizovat na určité použití.
- **ORM** – Minimum SQL příkazů a objemu přenášených dat. Úroveň izolace transakce.

### 5.6.3 Obsah plánu vykonání dotazu

V plánu lze získat informace:

- **consisteng gets** - logické přístupy + počet záznamů výsledků/velikost pole záznamů,
- **physical reads** - fyzické čtení,
- **sorts(memory)** - počet operací třídění, bez přístupu na disk,
- **sorts(disk)** - počet operací s nejméně jedním přístupem na disk,
- pokud pro logický přístup neexistuje fyzický => **cache hit** (cache hit rate = (cache hit / počet logických čtení) \* 100 [%])

- opačný případ **cache miss**,
- vhodné sledovat i další parametry **Bytes received from server**, **Total execution time**.

### S indexem pouze na primárních klíčích

| OPERATION                        | OBJECT_NAME   | OPTIONS        | COST |
|----------------------------------|---------------|----------------|------|
| SELECT STATEMENT                 |               |                | 1220 |
| NESTED LOOPS                     |               |                | 1220 |
| NESTED LOOPS                     |               |                | 1220 |
| TABLE ACCESS                     | STORE_ITEM    | FULL           | 1177 |
| Filter Predicates                |               |                |      |
| STORE_ITEM.NAME='PRA-2010-10000' |               |                |      |
| INDEX                            | SYS_C00203250 | UNIQUE SCAN    | 0    |
| Access Predicates                |               |                |      |
| STORE_ITEM.IDPRODUCER=PRODUCER.  |               |                |      |
| TABLE ACCESS                     | PRODUCER      | BY INDEX ROWID | 1    |

### S indexem na selektovaných atributech (WHERE ..)

| OPERATION                       | OBJECT_NAME     | OPTIONS        | COST |
|---------------------------------|-----------------|----------------|------|
| SELECT STATEMENT                |                 |                | 5    |
| NESTED LOOPS                    |                 |                | 5    |
| NESTED LOOPS                    |                 |                | 5    |
| TABLE ACCESS                    | STORE_ITEM      | BY INDEX ROWID | 4    |
| INDEX                           | STORE_ITEM_NAME | RANGE SCAN     | 3    |
| Access Predicates               |                 |                |      |
| STORE_ITEM.NAME='PRA-2010-1000' |                 |                |      |
| INDEX                           | SYS_C00203257   | UNIQUE SCAN    | 0    |
| Access Predicates               |                 |                |      |
| STORE_ITEM.IDPRODUCER=PRODUCER. |                 |                |      |
| TABLE ACCESS                    | PRODUCER        | BY INDEX ROWID | 1    |

## 6 Objektově-relační datový model a XML datový model: principy, dotazovací jazyky.

### 6.1 Objektový datový model

**Objektový datový model** představuje data uložené v **objektové struktuře**. Jde většinou o **objektovou mezivrstvu mezi kódem a databází**, do které se nasypou data, s kterými pak aplikace pracuje a nezatěžuje dotazy DB server.

Objektové databázové systémy umožňují využití hostitelského objektového jazyka jako je třeba C++, Java, nebo Smalltalk přímo na objekty (skládají se z **atributů a metod**) "v databázi"; tj. místo věčného přeskakování mezi jazykem aplikace (např. C) a dotazovacím jazykem (např. SQL) **může programátor jednoduše používat objektový jazyk k vytváření a přístupu k metodám**. Krátce řečeno, ODBMS (Object Database Management System) jsou výborné pro manipulaci s daty. Pokud navíc opomeneme programátorskou stránku, dá se říct, že některé typy dotazů jsou efektivnější než v RDBMS díky dědičnosti a referencím.

### 6.2 Objektově relační datový model

Objektově orientované DB → **nákladná migrace relačních dat**, proto vznikly **objektově-relační rysy** v relačních DB. (standart **SQL99** - víceméně se nedodrzuje, musíme se bavit o konkrétním SŘBD - Oracle).

ORDBMS využívají datový model tak, že "**přidávají objektovost do tabulek**". Všechny **trvalé informace jsou stále v tabulkách**, ale některé položky mohou mít **bohatší datovou strukturu**, nazývanou abstraktní datové typy (**ADT**). ADT je datový typ, který vznikne zkombinováním základních datových typů. Podpora ADT je atraktivní, protože operace a funkce asociované s novými datovými typy mohou být použity k indexování, ukládání a získávání záznamů na základě obsahu nového datového typu. OOSŘBD umožňují používat uživatelské typy, dědičnost, metody tříd, rozlišují pojmy instance a ukazatel na instanci.

#### 6.2.1 Prvky objektově-orientovaných SŘBD

- Uživatelsky definované **datové typy** (s atributy i metodami).
- Uložené **procedury, trigger**y (přenesení funkcionality na server).
- Kolekce (**pole** proměnné délky, **vnořené tabulky**).
- Datový typ **ukazatel, reference** a **dereference**.
- **Dědičnost** – `CREATE TYPE student_type UNDER person_type ( ... OVERRIDING MEMBER FUNCTION show...`

### 6.2.2 Výhody OOSŘBD

- **Objektové typy** a jejich **metody** jsou **uloženy spolu s daty** v databázi -> není nutné vytvářet podobné objekty v každé aplikaci.
- Na data je možné nahlížet z **relačního i objektového pohledu**.
- **Objekty** mohou **reprezentovat vazby**, kdy entita se skládá z jiných entit.
- **Metody** jsou **spouštěny na serveru** – nedochází k neefektivnímu přenosu dat po síti, část výkonu přenesena na server.
- Programátor může přistupovat k množině objektů jako by se jednalo o jeden objekt.

### 6.3 Typy tabulek a datové typy

- **Objektové tabulky** – obsahují pouze objekty, **každý záznam = objekt** (řádkový objekt).
  - **Objekty sdíleny dalšími objekty** by měly být uloženy v objektových tabulkách (mohou být **referencovány**).
  - Buď tabulka s **1 sloupcem objektů** (nad kterými lze provádět objektové metody), nebo tabulka obsahující atributy obj. dat. typu, nad kterou lze provádět relační operace (kompromis mezi O/RDM).
- **Relační tabulky** – Obsahují **objekty spolu s ostatními daty**, mluvíme o tzv. **sloupcovém objektu**.

#### 6.3.1 Objektově relační datové typy a metody

- Data/atributy, operace/metody.
- Normální používání **objektových typů** při definici atributů – `INSERT INTO contacts VALUES (person_type(65, ,John', ,Smith'), 2014-05-29)`
- **Objektový identifikátor (OID)** - identifikuje objekty objektových tabulek, není přístupné přímo, ale jen pomocí reference (typ REF). U relačních tabulek s objekty OID nepotřebujeme.
- **Reference na objekt** - REF, ukazuje na objekty stejného typu nebo hodnota NULL, **nahrazuje FK (cizí klíč), asociace/vztahy**. Pokud tabulka obsahuje referenci na objekt jedné tabulky, lze využít IO: `SCOPE IS tabulka`.
- **Dereference** - `SELECT Deref(e.manager) FROM emp_person_obj_table e`; **Implicitní dereference**: `SELECT e.name, e.manager.name FROM ....`

#### 6.3.2 Kolekce a dědičnost

Používané pro více hodnotové atributy nebo vazby M:N.

- **Pole** – VARRAY – variable-size array - pole pevné délky s definovanou kapacitou aktuální velikostí. DECLARE TYPE Calendar IS VARRAY(366) OF DATE.
- **Zahnížděná (nested) tabulka** – pole proměnné délky, záznamy ukládány bez ohledu na pořadí, ale po načtení z disku jsou záznamy očíslovány (nezachová hodnotu indexu, jen udrží pořadí).
- **Asociativní pole** – jako hash table - obsahuje dvojice <key, value>, kde key = číslo/řetězec, klíče jsou indexovány (žádné sekvenční vyhledávání). Nelze uložit do tabulky, spíše pro malé množství záznamů.
- **Hierarchická dědičnost** – v SŘBD můžeme vytvářet hierarchie typů pomocí dědičnosti. Tato vlastnost nám pak umožní využít všechny rysy objektově-orientovaných technologií, např. mnohotvárnost, polymorfismus.

### 6.3.3 Typy metod

- **Členské, statické, konstruktor** (pro každý obj. typ definován implicitně).
- **Volání:** SELECT c.contact.getID() FROM contacts c;

```
-- Vytváření objektu s atributy a metodou
CREATE TYPE person_type AS OBJECT (idno NUMBER, first_name VARCHAR2(20),
last_name VARCHAR2(25) , MAP MEMBER FUNCTION get_idno RETURN NUMBER);

-- Definice těla metody
CREATE TYPE BODY person_type AS MAP MEMBER FUNCTION get_idno RETURN
NUMBER IS BEGIN RETURN idno; -- vraci id END; END;

-- Objektové datové typy lze používat při definici atributů podobně jako SQL datové typy
CREATE TABLE contacts (contact person_type , contact_date DATE);

-- Záznam vložíme pomocí SQL INSERT:
INSERT INTO contacts VALUES (person_type (65, 'Verna' , 'Mills') , '24 Jun 2003') ;
```

## 6.4 XML Model a XML (eXtensible Markup Language)

- Značkový jazyk - W3C standard pro popis slabě strukturovaných dat.
- Data jsou uložena v xml souboru **formou stromu**. (Ve skutečnosti je to graf, ale pro zjednodušení se značí jen jako strom)
- **Logika a význam dat** je součástí xml souboru.
- Skládá se z **hlavičky**, **kořenového elementu** (právě jeden), **vnořených elementů**, **atributů** a **textu** vnořeném uvnitř (ukládáné informace).
- Soubor může obsahovat také tzv **XML Schema**, viz níže. To může určovat i datový typ a integritní omezení buněk, což je vhodné pro XML databáze.

XML databáze jsou složitější oproti relačním databázím. SQL pracuje s 2 rozměrnými tabulkami, zatímco XML model obsahuje i zanořené atributy. Proto se využívá dotazovací

jazyk X-Path. Největší výhodou nativní XML databází je **dynamická změna schémat** uložených dokumentů, která je u relačních databází velmi komplikovaná.

```
<?xml version="1.0"?>
<xsd:schema xmlns:xsd="http://www.w3.org/2001/XMLSchema">
  <xsd:element name="books">
    <xsd:complexType>
      <xsd:sequence>
        <xsd:element name="book" maxOccurs="unbounded">
          <xsd:complexType>
            <xsd:sequence>
              <xsd:element name="title" type="xsd:string"/>
              <xsd:element name="author" type="xsd:string"/>
            </xsd:sequence>
            <xsd:attribute name="id" type="IdType" use="required"/>
          </xsd:complexType>
        </xsd:element>
      </xsd:sequence>
    </xsd:complexType>
  </xsd:element>
  <xsd:simpleType name="IdType">
    <xsd:restriction base="xsd:string">
      <xsd:length value="9"/>
      <xsd:pattern value="[0-1]+-[0-1]+"/>
    </xsd:restriction>
  </xsd:simpleType>
</xsd:schema>
```

## 6.5 Dotazovací jazyky XML

Dotazovací jazyk XML by měl umět: vybrat požadované části dokumentů, transformovat je do požadované podoby, manipulovat s kolekcemi dokumentů a další vlastnosti specifické pro konkrétní problémovou doménu.

### 6.5.1 XPath

Jazyk používaný pro identifikaci uzlů v XML dokumentu. Pravděpodobně **nejdůležitějším** rysem jazyka XPath je **možnost vyjádření relativní cesty od uzlu k jinému uzlu či atributu**. Od jazyka SQL je značně odlišný. Určuje cestu s dodatečnými podmínkami na názvy uzlů, hodnoty atributů, hloubky zanoření a mnoho dalšího.

**Příklad:** `//zbozi[@sleva >= @cena div 2]`, který najde všechny elementy zboží, jejichž atribut `sleva` má hodnotu nejméně poloviny hodnoty atributu `cena`

### 6.5.2 XQuery

Připravovaný standard W3C (verze 1.0). XQuery **je silně typovaný jazyk**. Vychází z jazyka Quilt, inspirace XPath 1.0 a pro výběr částí dokumentů používá XPath 2.0.

- `$` – identifikuje proměnné,
- `for` – iterace přes něco,
- `where` – omezení výběru,
- `order by` – řadí,
- `return` – vrací výsledek,
- `let` – nastavuje hodnotu pro proměnnou.

```
for $x in doc("books.xml")/bookstore/book
where $x/price>30
order by $x/title
return $x/title
```

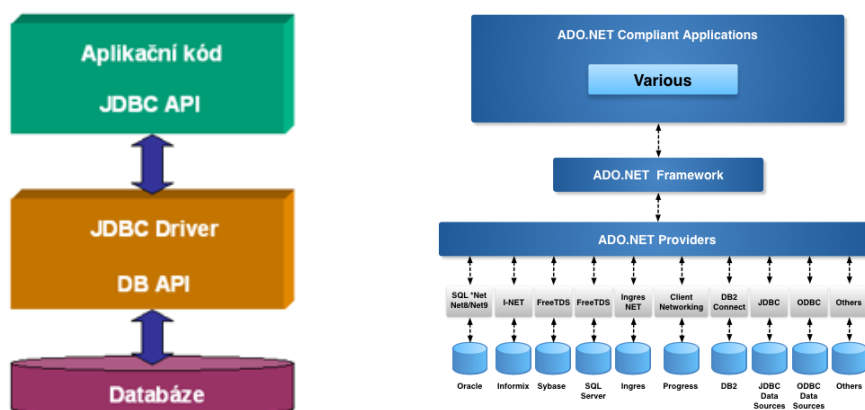


## 7 Datová vrstva informačního systému; existující API, rámce a implementace, bezpečnost; objektově-relační mapování.

### 7.1 Datová vrstva IS

Datová vrstva informačního systému **odděluje aplikaci od databáze**. Jde o třídy a funkce zajišťující komunikaci s databází. **Překonává propast mezi SŘBD a programovacím jazykem**. Nazývá se také perzistentní a je 3. (nebo 1. záleží na úhlu pohledu) vrstvou **třívrstvé architektury IS**.

Jedná se třídy a funkce, které se starají o persistentní ukládání dat, odtud také název. Datová vrstva nemusí nutně ukládat data do databáze, ale klidně do JSONu, XML, nebo přes API na jiných serverech. Proto je oddělená, aby bylo možné měnit „poskytovatele“ dat. Proto se programátor nemusí starat o fyzické uložení dat, pouze o práci s nimi.



- **Nástroje** – programovací jazyky + **SQL**, staví na **API pro dotazování DB** (JDBC, ADO.NET), **embedded SQL** - hostitelský jazyk obsahuje SQL.
  - **ODBC** (Open DataBase Connectivity) – standartizované API pro přístup k databázovým systémům. ODBC se snaží poskytovat přístup nezávislý na programovacím jazyku, databázovém systému a operačním systému.
  - **JDBC** (Java DataBase Connectivity) – Javovské API pro unifikovaný přístup k databázi. Bez ohledu kde jsou data uložena - SQL databáze, Oracle, XML, CSV, DB2, Ingress, ... – se s nimi přes JDBC pracuje stejně.
  - **ADO.NET** (Active Data Object) – specifikace (knihovna) pro přístupu k datový zdrojům na platformě .NET.
  - **ASP.NET** – knihovny pro informační systémy na platformě .NET. Pro komunikaci s databázi využívají ADO.NET.
  - **Java2EE** – knihovny pro informační systémy na platformě Java.
- **Speciální prostředí** – implementováno výrobcem SŘBD (Oracle Forms, APEX). Jednoduché, šité na míru, není připravené pro velké projekty a týmový vývoj.

- **Architektury** – jsou **komplikované, vícevrstvé**, ale umožňují jednodušší vývoj a zapojení více vývojářů. (3-vrstvá architektura => Business, Data, Presentation layer).

### 7.1.1 JDBC

- Rozhraní pro **unifikovaný přístup k datům** v DB na platformě **Java**.
- Inspirováno rozhraním **ODBC**.
- Zprostředkování komunikace aplikace s konkrétním typem DB (ovladače k většině).
- **Dotazovací jazyk – SQL**. Předá se DB, ovladač vyhodnotí přímo.
- **Schéma provedení dotazu**: 1) Připojení k datovému zdroji. 2) Inicializace. 3) Vytvoření a provedení dotazu. 4) Získání výsledku. 5) Ukončení transakce. 6) Odpojení od datového zdroje.
- Hlavní třída **Connection** - odesílá **Statementy** a obdrží **ResultSety**.
- **Podpora transakcí** (implicitně, každý příkaz jedna transakce, jsou vázány k instanci connection).

### 7.1.2 ADO.NET

- **Connection** spouští **Commandy**, výsledkem je **DataSet** (použití **DataAdapteru**) nebo čistá data čtená **DataReaderem**.
- **DataSet** -> **DataTable[]** -> **DataRow[]** -> **DataColumn[]**
- **DataRelation** vazba mezi **DataSety** s vazebním **DataColumn**.
- Umožňuje **parametrizovat commandy**.
- Třída **TransactionScope** pro distribuované transakce.

## 7.2 ORM (Objektově-relační mapování)

Programovací technika **zpřístupňující relační či objektově-relační data pro objektové prostředí**. Entita v ORM je objekt, který je uložen v SŘBD (nejčastěji jako jeden záznam). Nejčastěji je implementován jako třída. Díky rozhraní jsou jednotlivé implementace zaměnitelné. Vlastnosti ORM rámců:

- Práce s objektovým modelem (přenositelnost mezi různými SŘBD).
- Překonává propast mezi SŘBD a programovacím jazykem.
- **Rychlejší vytváření aplikací** vs Menší výkon aplikace.
- Nemusí využívat všechny vlastnosti SŘBD (efektivita, bezpečnost apod.). Záleží na komplexnosti a kvalitě knihovny ORM.
- Typová kontrola (nevznikají chyby v SQL).
- Jednodušší testování.

- Může využívat existující API jako JDBC, ADO.NET apod.
- Měly by se používat pouze metody a parametry ORM, nikoli přímo SQL dotazy.
- Využívá známé návrhové vzory **Table data gateway**, **Row data gateway**, **Active record**, **Data mapper**.
- Dobré ORM si dokáže poradit i s dědičností pomocí návrhových vzorů **Single-table inheritance**, **Class table inheritance** a **Concrete table inheritance**.

### 7.2.1 Pravidla ORM

- **Minimalizace počtu dotazů** zasílaných na server.
- **Minimalizovat objem dat** získaných z DB, stahovat pouze ta data, které potřebujeme, a které jsou zobrazeny uživateli (Lazy Loading).

### 7.2.2 Vlastní implementace ORM

- Využití **API pro komunikaci s DB** (JDBC, ADO.NET).
- Používá se **SQL**.
- **Výhody:** plná kontrola nad výkonem (stahujeme jen to co chceme) a prováděnými příkazy. Můžeme využít konkrétní prvky daného SŘBD.
- **Nevýhody:** aplikace je závislá na určitém typu SŘBD, při rozšiřování systému je často nutné rozšířit také ORM.

### 7.2.3 Automatizované

- Frameworky **Hibernate** (Java), **LINQ2SQL**, **EntityFramework** (ASP.NET).
- Může výrazně **degradovat výkon** (musí provádět interpretaci do SQL, vytváří objektový model atd.).
- Většinou mají vlastní **cache**. Většinou jsou **nezávislé na daném SŘBD**.

## 7.3 Bezpečnost

**(Ne)Omezení práv** - uživatel může destruktivně vymazat celou DB, nebo číst data, která nemá. **Řešením** je omezení práv na jednotlivé akce, či úplné zamezení viditelnosti tabulek. Pro zobrazení jejich částí lze využít pohledy.

**SQL Injection** - zranitelnost vznikající při nedostatečném **ošetření vstupů uživatelských** v SQL dotazech. Např.: při přihlašování na webových stránkách zadá útoční příkaz SQL, které změní funkčnost dotazovaného příkazu. **Řešení:**

- **Parametrizované dotazy** (hodnoty jsou předány zvlášť, nemůže dojít k úpravě).
- Uložené procedury.

- Ošetření vstupů (`htmlspecialchars`, `mysql_real_escape_string`) - zneužití např. pomocí jiného kódování!
- Uživatel musí zadávat komplikovaná (neslovníková) hesla, **časové omezení počtu** pokusů. Logování neúspěšných pokusů o autentizaci.

## 7.4 Způsoby doménově-relačního chování

- **Table data gateway** - Vrací Dataset DTO bez znalosti domény. Dataset obsahuje pole řádků, i když je navrácen pouze 1. Jediná instance drží i více řádků tabulky. Protože nezná doménu, každá funkce obsahuje tolik parametrů, kolik je sloupců.
- **Row data gateway** - Každý řádek je 1 objekt. Obsahuje funkce pro `update` `delete`. Je potřebná nějaká statická třída `Finder` pro vytváření nových instancí, protože pokud nejsou data, neexistuje ani objekt.
- **Active record** - Každá instance je 1 řádek. Obsahuje i funkce `insert` a `update` atd. Ale také metody pro práci v programu, různé výpočetní apod.
- **Data mapper** - Mapper třída mapuje z DB data na objekty a zpět. Každý objekt obsahuje veškeré parametry a také funkce pro práci s nimi na úrovni programu. Do mapperu se nevkládají jednotlivá data jako parametry ale vždy daný objekt, který samotný funkce pro práci s DB postrádá.

## 8 Distribuované SŘBD, fragmentace a replikace.

### 8.1 Distribuované SŘBD


Distribuovaný databázový systém (DDBS) je tvořen **distribuovanou bází dat** a **programovým vybavením**, skládajícím se z **lokálních SŘBD** a dalších programů potřebných k jejich **koordinaci a řízení**, k zabezpečení celosystémových úloh spojených s přístupem uživatelů k DDBS, s udržováním integrity a provozuschopnosti v prostředí počítačové sítě. **Uživatelé se jeví celá distribuovaná báze jako by byla lokální** (na jednom místě) a přistupuje k ní stejným způsobem.

Podle toho jak je dist. databáze řešena a kam směřují dotazy ji dělíme na:

#### 8.1.1 Centralizované

Mají popis a řízení DDBS soustředěno na **1 centrální počítač**. Toto centrum nemusí být v centru počítačové sítě. Jsou zde soustředěny **popisky všech dat** tvořících DDBS a **centrálně se řídí: přístup k datům, provádění změn** ve struktuře dat, **provádění a synchronizace transakcí** + všechny další činnosti systému.


- **Výhody** – jednoduchost řízení.
- **Nevýhody** – vysoké náklady na komunikaci, pomalost (každý přístup k datům musí být povolen centrem) a nebezpečí výpadku tohoto jednoho prvku.



#### 8.1.2 Decentralizované

Jsou tvořeny počítačovou sítí, kde žádný uzel nemá privilegované postavení. **Všechny počítače mají stejné informace o DDBS a stejnou odpovědnost za integritu DDBS.**

- **Výhody** – větší stabilita (výpadek počítače způsobí max. ztrátu přístupu k lokálním datům).
- **Nevýhody** – složitější algoritmy pro řízení transakcí než v centralizovaných DDBS.



## 8.2 Rozmístění dat (fragmentace a replikace)

U DDBS jsou nejvíce časově náročné operace přesunu dat po komunikační lince. Vzhledem k vyšší možnosti poruch je třeba relace ukládat tak, aby jejich **dostupnost byla zajištěna** i v případě výpadku části sítě. Relací zde rozumíme logický celek, ale fyzicky i více souborů. Používají se **2 hlavní způsoby** fyzické implementace:

- **Replikace** – (přítomnost duplicitních dat) **uchovávání kopií relací v různých uzlech, porucha uzlu neznemožní přístup k relaci** (díky tomu se dist. databáze i samozálohuje), problém je v aktualizaci všech kopií relací. Proto se v DDBS ukládají v kopiích ta data, ke kterým je třeba **rychlý přístup** a nejsou často aktualizována a jsou velmi důležitá.
- **Fragmentace** – znamená **rozložení relací na menší části** (fragmenty), které jsou umístěny v různých uzlech sítě. Může jít o **horizontální** fragmentaci, kdy se v různých uzlech sítě ukládají části relace rozložené do skupin řádků nebo **vertikální** fragmentaci, kdy se v různých uzlech ukládají různé projekce relací. Fragmentace se provádí, aby se **původní relace získala zpět standardními operacemi nad relační databází** (sjednocení, spojení).

Obě metody se často kombinují tak, že se v distribuované bázi uchovávají kopie fragmentů v různých uzlech. V distribuované databázi musí být unikátní jména všech položek. Tedy ani 2 lokální položky nesmí používat stejná jména pro různé položky. Jednou z možností jak tento problém vyřešit je **centrální slovník**, ovšem ten je zase úzkým místem systému.